

音声コンテンツの自動セグメント化と トピックモデリングによる推薦システムの構築

Building a Radio Program Recommendation System through Automatic Segmentation and Topic Modeling of Audio Content

野本匠馬

Takuma Nomoto

法政大学情報科学部デジタルメディア学科

Email: takuma.nomoto.3z@stu.hosei.ac.jp

Abstract

Currently, audio content such as radio and podcast programs are distributed in a wide variety of formats. However, it is time-consuming and difficult for users to find programs that they might like or parts of programs that interest them.

The purpose of this research is to develop a system that recommends segments such as corners and talk zones in radio programs based on the user's interests. In a program consisting of multiple segments, each segment has its own characteristics, so it is difficult to find a segment that you like unless you watch the entire program. This creates a problem in that you must spend time on parts that you are not interested in. In this research, we remove music and commercials from radio programs and use LDA to extract topics of the segments. Then, we identify and recommend segments that have topics similar to the user's interests. We evaluate the system by the user to reduce the time burden and evaluate whether they can access only the content they want to listen to.

1. はじめに

現在、多種多様な形で膨大な数のラジオ番組やポッドキャストなどの音声コンテンツが配信されている。しかし、ユーザー自身がその中から気に入るような番組や番組内の興味のある部分を探すことは時間や手間がかかり困難である。これは各番組がそれぞれ特徴のあるコーナーやトークゾーン等で構成されており、ユーザーが番組を気に入るかどうかは実際に番組全体を聴かなければならないことが原因である。また、興味のあることについて聴くまでに興味のないことも聴く必要があることも原因となっている。例として、「オーードリーのオールナイトニッポン」を挙げる。この番組のアピールポイントは、人気のあるお笑い芸人コンビがパーソナリティを務める番組で、10年以上継続しており、高校時代の話が人気であるとする。しかし、それが深夜放送で放送時間が2時間だとすると、ユーザーは聴くことが面倒だと感じる可能性がある。また、このユーザーが高校時代の話に興味のあることとしていると、その部分を聴く前に再生をやめてしまう可能性がある。この場合、インターネット

トラジオである radiko の過去一週間以内に放送された番組が聴けるタイムフリー機能やポッドキャストによるアーカイブ配信によって、ユーザーが放送開始時間に起きていなくてはならない問題は解決できている。しかし、一方で長時間聞く必要がある問題と興味のないことも聴かなくてはならない問題は解決できていない。

ラジオ番組の推薦には SNS データを用いた手法やそれに協調フィルタリングを用いた場合が挙げられる。しかし、これらが推薦するのは番組全体であるので、長時間聞く必要がある問題を解決できていない。よって、興味のないことも聴かなくてはならない問題も解決できていない。このことから、ユーザーの興味のあることから番組を聞かせるような推薦手法が望まれる。したがって、番組を内容の話題ごとに分割する必要がある。

本研究では、ラジオ番組をトピックで分割してトピックセグメントを作成し、ユーザーの興味に応じてそれらを推薦するシステムを提案する。本研究において、トピックは番組内で話されている話題、トピックセグメントはトピックについて話している音声データである。トピックセグメントはトピックで分割されているため、ユーザーは興味のあるトピックから聴くことができる。また、トピックセグメントを聴くために要する時間は分割する前の時間より短くなるので、ユーザーは気軽に聴くことができる。したがって、興味のないトピックも聴かなくてはならない問題と長時間聴く必要がある問題を解決できる。

2. 関連研究

ラジオ番組の推薦手法には、SNS データを用いた手法やそれに協調フィルタリングを用いた手法がある[1]。丸山らは、提案されているラジオ番組推薦手法の評価を行い、Twitter 上のユーザーコミュニティを活用した協調フィルタリングやグラフベース手法が有効であることを明らかにしている[2]。Fernández-García らは、ラジオ番組の音楽とトークの割合、音楽のジャンル、扱うトピック、声のトーンを反映した推薦システムを開発した[3]。太田らは、ラジオリスナーのユーザー体験向上のために、Twitter のデータを用いてラジオ番組の盛り上がっている区間を推定し、その区間以外を高速化することでラジオ番組の圧縮手法を提案した[4]。

データをトピックで分割する手法としてトピックセグメンテーション手法である Text Tiling が挙げられる[5]。Text Tiling は文書のある境界において、左右に一定の単語数を保持する窓と呼ばれるブロックに分ける。そして、




図 1: トピックセグメント推薦システムの全体構成図

左右のブロックの類似度を求め、両方のブロックを左から右に進める。この操作を繰り返し、類似度の谷をトピックが変わった場所と見なして分割する手法である。福田らは、話し言葉は文法的な表現が安定しないことから、文書内の語の共起関係に着目し、意味的に近い語がまとまっている部分をセグメントとする手法を提案した[6]。また、Text Tiling を発展させた手法として、Topic Tiling が提案されている[7]。Topic Tiling では、左右の窓に対してトピックモデルである LDA を適用してベクトルにする。左右のベクトルのコサイン類似度から窓間の結束度を計算する手法である。山村らは、語彙的連鎖を利用して分割を行う LC-seg と、LDA がどちらも異なる情報を用いていることから、両手法を組み合わせた手法を提案している[8]。

既存手法は番組を聴いたリスナーの感想を解析しているので、番組に対するユーザーの声を反映させることができる。しかし、SNS データを用いた手法では、データに間違った情報や偏った情報などのノイズが存在していた場合に適切な推薦が困難になる。また、協調フィルタリングでは、過去データがない新規ユーザーに対しての推薦が困難である。そして、既存手法では番組単位で推薦しているため、番組を長時間聞く必要がある問題を解決できていない。

本研究では、番組をトピックで分割してトピックセグメントにすることで、長時間聞く必要がある問題を解決している。また、ユーザーは推薦されたセグメントから番組が面白いかどうかを暫定的に判断することができる。面白いと判断した場合、その番組の他のトピックセグメントや実際の番組を聴くことで、その番組のリピーターになる可能性が高まる。

3. トピックセグメント推薦システム

3.1. トピックセグメント推薦システムの構築

トピックセグメント推薦システムの全体図を図 1 に示す。本システムはラジオ番組をトピックセグメントに分




図 2: トピックセグメント分割部

割するトピックセグメント分割部とユーザーの興味に応じてトピックセグメントを推薦するトピックセグメント推薦部から構成される。ラジオ番組から番組音声データを取得し、これをトピックで分割することでトピックセグメントを作成する。また、トピックの情報を参照・取得するために、トピック辞書とトピックセグメントデータベースを用いる。トピック辞書はラジオ番組の文字起こしテキストデータから推定した各トピックの識別番号、関連名詞、関連名詞ごとの生起確率を保持した辞書である。トピックセグメントデータベースは作成したトピックセグメントとトピックセグメントが保持する情報をトピックごとに複数個格納できるデータベースである。そして、類似トピックに対応するトピックセグメントをデータベースから取得して、ユーザーに推薦する。類似トピックとは、番組内のトピックに対して、ユーザーの興味のあることに類似したトピックである。本システムの各モジュールの詳細は次項以降行う。

3.2. トピックセグメント分割部

図 2 にトピックセグメント分割部の全体像を示した。まず、ラジオ番組から番組音声データを取得する。次に番組音声データから音楽・CM 部分を除去し、発話音声データを抽出する。次に、これに対して文字起こしを行い、発話テキストを取得する。発話テキストからトピック区間を特定し、発話音声データにおけるトピック区間の開始時刻と終了時刻を特定する。そして、特定した開始時刻から発話音声データを再生するように切り出すことでトピックセグメントを作成する。これらをトピックごとにトピックセグメントデータベースに格納する。また、発話テキストから LDA モデルを構築し、生成したト




図 3:「星野源のオールナイトニッポン」のスペクトグラム




図 4:録音した音声データのスペクトグラム

ピックの関連名詞とそれぞれの生起確率を保持した辞書を作成する。各処理の詳細な説明は次項以降で行う。

3. 2. 1. 番組音声データの分割

ラジオ番組はパーソナリティの発話部分とジングルなどの音楽部分、CM 部分から構成される。番組をトピックで分割するとき、トピックは番組の内容から抽出することとなる。このとき、番組の内容を番組の進行をしているパーソナリティが発話している部分とする。このことから、番組音声からパーソナリティの発話部分を抽出する必要がある。したがって、番組から音楽部分と CM 部分を除去して、発話部分である発話音声データに分割する。

まず、番組音声データから音楽部分を除去するためにスペクトル解析を行う。ラジオ番組では、コーナーやトークゾーンなどの開始時と終了時にジングルが流れ、その後にはわずかに無音区間が流れる特徴を利用する。スペクトル解析には Python の音響解析及び信号処理のライブラリである Librosa を用いた。また、音声データの分割は音声ファイルを入出力するためのライブラリである Pydub を用いた。

図 3 に「星野源のオールナイトニッポン」、図 4 に録音した音声データにそれぞれスペクトル解析を行った結果を示す。これらの結果の濃い青色の部分つまり音の強度が特に弱くなっている部分に対応している時間の元の音声データではジングルが流れていた。

このことからスペクトル解析を行い、音の強度が閾値より弱い区間を検出することで番組音声データを音楽部分で分割する。しかし、分割した音声データが CM 部分を含んでいる場合があるので、分割したデータをさらに

発話者:	SPEAKER_03,	開始時刻:	665.46284375,	終了時刻:	666.3572187500001
発話者:	SPEAKER_03,	開始時刻:	666.7453437500001,	終了時刻:	669.24284375
発話者:	SPEAKER_03,	開始時刻:	669.47909375,	終了時刻:	679.75596875
発話者:	SPEAKER_03,	開始時刻:	680.1440937500001,	終了時刻:	691.04534375
発話者:	SPEAKER_03,	開始時刻:	692.1928437500001,	終了時刻:	692.44596875
発話者:	SPEAKER_03,	開始時刻:	702.85784375,	終了時刻:	706.1484687500001
発話者:	SPEAKER_03,	開始時刻:	706.62096875,	終了時刻:	708.5615937500002
発話者:	SPEAKER_03,	開始時刻:	709.18596875,	終了時刻:	709.9453437500001
発話者:	SPEAKER_03,	開始時刻:	872.9240937500001,	終了時刻:	876.1809687500001
発話者:	SPEAKER_03,	開始時刻:	876.53534375,	終了時刻:	878.2903437500001
発話者:	SPEAKER_03,	開始時刻:	878.6615937500001,	終了時刻:	879.60659375
発話者:	SPEAKER_03,	開始時刻:	879.9440937500001,	終了時刻:	881.3953437500002
発話者:	SPEAKER_03,	開始時刻:	881.68221875,	終了時刻:	882.7453437500001
発話者:	SPEAKER_03,	開始時刻:	882.94784375,	終了時刻:	883.9265937500002

図 5:「星野源のオールナイトニッポン」のセグメントの話者分離の実行結果

話者分離を用いて分割する。

次に、スペクトル解析で除去できなかった CM 部分を除去するために話者分離を行う。音声データ内で 60 秒以上発話している話者をメインスピーカーと定義した。メインスピーカーが 30 秒以上発話していなかった時に、CM 部分に遷移したと認識して分割を行う。話者分離にはオープンソースフレームワークである pyannote.audio を用いた。

図 5 に「星野源のオールナイトニッポン」の発話音声データに対して、話者分離を行った結果を示す。実行結果は上の行から下の行へ時系列順になっており、左から発話者の ID、発話者の発話開始時間、発話者の発話終了時間を表している。この発話音声データでは SPEAKER_03 がメインスピーカーとされていた。図 4 の 8 行目の終了時刻と 9 行目の開始時刻の差が約 163 秒となっているため、CM 部分に遷移したと認識されて分割が行われている。

このようにスペクトル解析と話者分離を用いることで、ラジオ番組から音楽部分と CM 部分を除去した。

3. 2. 2. 発話音声データの分割

ラジオ番組の内容をトピックで分割するためにトピックモデルである LDA を用いる。LDA はテキストデータからトピックを推定するため、発話音声データを文字起こしして発話テキストを取得する。本研究では、トピックの流れを細かく見るために Topic Tiling を行う。これによって、トピック区間を特定して、この部分を発話音声データから切り出すことでトピックセグメントを作成する。トピックセグメントとこの情報をトピックセグメントデータベースに格納する。また、トピックの情報をトピック辞書として取得する。

まず、発話音声データから発話テキストを取得するために、faster-whisper の large-v3 モデルを用いて文字起こしを行った。このとき、各発話の開始時刻と終了時刻を同時に取得する。図 6 は「星野源のオールナイトニッポン」の一部を文字起こした結果である。N-gram にしてトピックシーケンスを推定するとき、フィラーや名詞が含まれない文などの発話内容に関係のない発話は境界を見つける際のノイズとなる可能性があるため、このような発話は除去する。除去した文字起こし結果を図 7 に示す。

本研究では、トピックとなる得る単語の品詞は名詞であると考えた。名詞のみを抽出するために日本語形態素エンジンの McCab を用いる。また、形態素解析を行う際には、名詞一般、名詞-固有名詞、名詞-サ変接続である名詞を取得する。また、新語や固有名詞に対応するために形態素解析用辞書の NEologd を適用する。しかし、こ

[0. 40, 2. 52]:: どうもこんばんは星野源です
 [2. 52, 10. 44]:: 今日は2024年9月10日火曜日25時でございます
 [10. 44, 16. 92]:: そして星野源のオールナイトニッポンがなんと398回ってことで
 [16. 92, 18. 88]:: おーやりましたねやってますね
 [18. 88, 21. 88]:: もうちょっとで400回ってことで
 [21. 88, 25. 00]:: 今日は通常放送かと思いきや
 [25. 54, 27. 18]:: オールナイトニッポン全体がですね
 [27. 18, 29. 34]:: 1週間ミュージックウィークということで
 [29. 34, 33. 22]:: いつもねいろんな芸人さんやら俳優さんやら
 [33. 22, 34. 98]:: いろんな方がいますけれども
 [34. 98, 39. 56]:: 今日はミュージシャンばかりが出る週ということで
 [39. 56, 43. 10]:: いつもは出ない方々などがこの1週間ね
 [43. 10, 45. 56]:: いろいろにぎにぎにぎにぎしております
 [45. 56, 49. 60]:: で僕とあのちゃんだっけだっけあれ
 [49. 60, 52. 30]:: あと北谷さんだそうだ北谷さん
 [52. 30, 56. 10]:: お会いしたこと多分ちゃんとお話したことはないんですけど
 [56. 34, 58. 44]:: 北谷さんとかは
 [58. 44, 58. 70]:: えー
 [58. 70, 61. 48]:: もともとね音楽の人なので

図6:「星野源のオールナイトニッポン」の文字起こし結果

のように構築した MeCab では、'いやいや'、'わからん'などの感動詞の組み合わせや動詞と助動詞の組み合わせが1つの名詞として取得されてしまう。これは NEologd が過剰に名詞を取得してしまうことが問題である。このことから、この MeCab で名詞を取得した後に、各名詞に対して、IPA 辞書を適用した MeCab を用いて、助詞や助動詞を含む名詞、名詞が含まれない名詞を除去することで、過剰に名詞を取得してしまう問題を解決する。LDA モデルの実装には様々なトピックモデルを実装したライブラリである gensim を用いる。また、抽出した名詞の埋め込み表現には東北大学の乾研究室が公開している事前学習済み日本語 BERT モデルを用いる。以降、BERT はこのモデルを用いる。

次に、発話音声データの内容からトピックを推定するためにトピックモデルである LDA (潜在的ディリクレ配分法) を用いる。複数の発話テキストから LDA モデルを構築することで、発話テキストにおける各トピックの生起確率をトピック分布として取得できる。また、各トピックにおいて生起確率が高い単語を単語分布として取得できる。このことから、LDA モデルで推定したトピックの単語分布において、生起確率の上位 10 単語を関連名詞とし、関連名詞とその生起確率をトピック辞書として保持する。このとき、トピック辞書において、1つのトピックに対して、1つの意味的なまとまりが対応するようにトピック辞書を調整する。トピック辞書の調整では、生起確率が閾値以下の関連名詞を除去する。次に、関連名詞を BERT でベクトルに変換し、ベクトル間の類似度と最小クラスサイズをパラメータとしたクラスタリングを行う。このとき、ベクトル間の類似度はベクトルの距離指標、最小クラスサイズはクラスが成立する最小のデータ数のことである。そして、複数のクラスが形成された場合はクラスごとに分割し、それぞれを新しいトピックとしてトピック辞書に登録する。このようにす

[0. 40, 2. 52]:: どうもこんばんは星野源です
 [2. 52, 10. 44]:: 今日は2024年9月10日火曜日25時でございます
 [10. 44, 16. 92]:: そして星野源のオールナイトニッポンがなんと398回ってことで
 [18. 88, 21. 88]:: もうちょっとで400回ってことで
 [21. 88, 25. 00]:: 今日は通常放送かと思いきや
 [25. 54, 27. 18]:: オールナイトニッポン全体がですね
 [27. 18, 29. 34]:: 1週間ミュージックウィークということで
 [29. 34, 33. 22]:: いつもねいろんな芸人さんやら俳優さんやら
 [34. 98, 39. 56]:: 今日はミュージシャンばかりが出る週ということで
 [39. 56, 43. 10]:: いつもは出ない方々などがこの1週間ね
 [43. 10, 45. 56]:: いろいろにぎにぎにぎにぎしております
 [49. 60, 52. 30]:: あと北谷さんだそうだ北谷さん
 [56. 34, 58. 44]:: 北谷さんとかは
 [58. 70, 61. 48]:: もともとね音楽の人なので

図7:「星野源のオールナイトニッポン」の文字起こし結果(内容に関係のない文は除去)




図8: トピックセグメント推薦部

ることで、1つのトピックに対して、1つの意味的なまとまりを持つトピック辞書を作成できる。

そして、発話テキストにおいて、細かくトピックを認識してトピック区間を特定するために、発話テキストの連続するN行をトークンとしたN-gramを1つの窓とした Topic Tiling を行う。このとき、左右の窓に対して、それぞれトピック辞書を用いてベクトルに変換することで、窓間の類似度を計算する。そして、窓間の類似度が閾値以上または未滿に切り替わる時点でテキストを分割する。これにより、トピック区間の開始時刻と終了時刻を特定し、開始時刻から発話音声データを再生するトピックセグメントを作成する。そして、トピックセグメントにトピック辞書を用いて推定したトピックセグメントのトピック分布をトピックセグメントデータベースに格納する。

3.3. トピックセグメント推薦部

図 8 にトピックセグメント推薦部の全体像を示した。トピックセグメント推薦機能では、ユーザーに興味のあることの文を入力させる。次に、ユーザーの興味のあることとトピック辞書から類似トピックを特定する。そして、類似トピックに対応するトピックセグメントを推薦する。

まず、ユーザーが入力した興味のあることについての文から名詞を抽出する。抽出した名詞とトピック辞書から類似しているトピックを特定する。抽出した名詞とトピック辞書のあるトピックの関連単語群との類似度が閾値以上となるトピックを類似トピックとする。

本研究では、トピック類似度の計算にコサイン類似度を用いる。そのため、抽出した名詞や関連単語を BERT で埋め込み表現にする。そして、抽出した名詞と関連単語について、コサイン類似度を計算する。計算したコサイン類似度に、関連単語の生起確率を乗算する。各関連単語の類似度の平均値をトピック類似度として扱う。全てのトピックに対してトピック類似度を計算し、閾値以上のトピックを類似トピックとする。

特定した類似トピックに対応しているトピックセグメントを取得し、推薦する。

本研究では、取得したトピックセグメントにおいて、類似トピックの生起確率が高い順に推薦を行う。また、生起確率が同じである場合には、トピックセグメントの再生時間が短いものを先に推薦する。

4. 評価実験

本実験では、ユーザーの興味のある部分のみを推薦するために、トピックセグメントが適切に整形されているかを分析する。本研究では、ユーザーが入力した文から抽出した名詞とトピック辞書の関連名詞の意味的類似度を計算することでユーザーが聴きたいトピックに類似したトピックを特定する。このとき、関連名詞が意味的に類似していなければ、ユーザー入力文の名詞との類似度計算において、高い類似度と低い類似度の関連名詞が両方とも存在してしまう。これでは、ユーザーの興味と関連名詞全体の類似度を正確に計算することが困難になる。このことから、トピックセグメントには 1 つのトピックのみを含めるべきである。トピックセグメントの内容とそれに付与されたトピックが意味的に類似しているものを正解とみなし、トピック辞書を調整しない場合とトピック辞書の調整の仕方による正解率の変化を調査する。

4.1. 実験方法

使用するデータとして、2024 年 6 月 24 日から 12 月 24 日までの「星野源のオールナイトニッポン」18 回分の音声を使用し、これの文字起こしデータから LDA を構築して、トピック辞書を作成し、これを用いてトピックセグメントを作成した。

実験方法について、トピック辞書を調整しない場合と調整する場合の両方で、トピックセグメントの発話テキストから名詞を抽出し、BERT でベクトルに変換した後、それらの平均ベクトルを計算する。そして、付与されているトピックの関連名詞を BERT でベクトルに変換して、それらの平均ベクトルを計算する。2つの平均ベクトルのコサイン類似度を計算し、閾値以上であれば正解とみなす。

用意した 100 個のトピックセグメントにおいて、トピック辞書を調整する際のパラメータを変化させることで正解率がどのようになるか比較する。

4.2. 実験結果

トピック辞書を調整する際のクラスタリングにおけるパラメータであるベクトル間の類似度を Similarity、クラスタの最低ベクトル数を Cluster size と定義する。トピックセグメントの平均ベクトルと付与されたトピックの平均ベクトルのコサイン類似度が閾値以上の場合、そのトピックセグメントを正解とみなす。

図 9 では、100 個のトピックセグメントに対し、トピック辞書の調整有無ごとに Similarity と Cluster size を変化した場合の正解の割合を示す。横軸は正解とみなす類似度の閾値 (0.05 刻みで 0.05 から 1.0)、縦軸は正解率を表す。赤線はトピック辞書を調整しない場合、青線は調整する場合の結果を示し、閾値の変化による割合の推移を比較する。

4.3. 考察

トピック辞書の調整において、変化させるパラメータにおいて、Similarity を大きくすると、トピック辞書の関連名詞がより意味的に類似したまとまりを持ち、Cluster size を大きくすると、そのような関連名詞をより多く含むようになる。このことから、Similarity と Cluster size を同時に大きくすることで、より統一性の高いトピック辞書を作成できる。また、本実験において、グラフの横軸の値が大きいときに、正解率が高ければ、トピックセグメントの内容とトピックがより類似していると言える。


図 9 の(a), (b)の結果から、Cluster size が 2 の場合では、Similarity が 0.7 だと、調整したトピック辞書の正解率が調整しなかった場合を下回ることがわかる。これは、両方のパラメータが小さいことから、関連名詞を小さなまとまりで分割することができ、より細かいトピックを認識できるが、このようなトピックが付与されているトピックセグメントには、不要な名詞が含まれやすく、この平均ベクトルとトピックの平均ベクトルのコサイン類似度が低下するためである。一方、Similarity を 0.8 にすると、関連名詞のまとまりが厳密になり、正解率が向上した。

また、図 9 の(c)では、調整の有無による大きな差は見られなかった。このことから、調整の有無に関わらず、同様のトピックセグメントが作成されたと考えられる。Cluster size が大きくなると、類似している関連名詞をまとまりと見なす条件が厳しくなることで、より一般的なトピックが保持されると考えられる。


図 9 の(d)では、Similarity と Cluster size を共に大きくした場合で、閾値が 0.8 のときに、正解の割合が 20%程度向上し、9 割程度のトピックセグメントが正解に分類された。本システムでは、調整したトピック辞書と正解と見なされたトピックセグメントを活用することで、ユーザーの興味に適したトピックを特定し、適切なトピックセグメントを推薦することが可能となる。

5. まとめ


本研究では、音声コンテンツをトピックごとに分割し、ユーザーの興味に基づいて適切なトピックセグメントを推薦するシステムを構築した。トピック辞書を調整することで、トピックセグメントの内容と付与されたトピック




(a) [Similarity = 0.7 , Cluster size = 2]



(b) [Similarity = 0.8 , Cluster size = 2]



(c) [Similarity = 0.7 , Cluster size = 3]



(d) [Similarity = 0.8 , Cluster size = 3]

図9: トピックマッチセグメントの割合

クの意味的類似性を向上させ、9割程度のトピックセグメントに適切なトピックを付与できた。

しかし、本システムにはいくつかの課題が残されている。まず、本システムでは *faster-whisper* の *large-v3* を用いて発話テキストを取得しているが、人物名の表記ゆれが発生しやすく、例えば「キタニタツヤ」という名前が「北谷」と誤認識されるケースが確認された。このような誤認識によって、トピックの抽出精度が低下するため、人物名などの固有名詞の名寄せを自動化する必要がある。また、トピック辞書の調整において、*Similarity* と *Cluster size* のパラメータを調整することで正解率を向上させることができたが、そのようなパラメータの値はデータセットによって異なる可能性がある。そのため、これらのパラメータをデータセットごとに動的に設定できる仕組みを導入する必要がある。

今後の展望としては、トピック辞書を調整して得られたトピックセグメントが実際にユーザーの興味に合致しているかを評価する実験を行い、トピックセグメントの内容と付与されたトピックの意味的類似度がどの程度であればユーザーの興味に適合するとみなせるのかを検討する。また、ユーザーの興味が特定の人物に関する場合、その人物がメインスピーカーとして話しているラジオ番組を推薦するのか、それともその人物について言及されているトピックセグメントを推薦するのかといった選択肢を考慮し、システムのパーソナライズ化を進める。さらに、ラジオ番組のトピック遷移を可視化し、番組全体の構成や話題の流れを直感的に理解できるようにすることで、音声だけでなく視覚的にもラジオ番組の内容を把握できるシステムの構築を目指す。

参考文献

- [1]. 丸山 司, 岡本 一志, 柴田 淳司: 「SNS データを用いたラジオ番組推薦手法に関する調査」, The 36th Annual Conference of the Japanese Society for Artificial Intelligence, 2022.
- [2]. 丸山 司, 岡本 一志, 柴田 淳司: 「Twitter データ各要したラジオ番組推薦システムの検討」, DEIM Forum, 2023, 3b-7-1.
- [3]. Antonio Jesús Fernández-García, Roberto Rodríguez-Echeverría, Juan Carlos Preciado, Jorge Perianez, Juan D. Gutiérrez: "A hybrid multidimensional recommender system for radio programs". *Expert Systems with Applications*, Vol. 198, p. 116706, 2022.
- [4]. 太田暢, 村山太一, 矢田竣太郎, 荒牧英治, 若宮翔子: 「Twitter を用いたラジオ番組圧縮手法の提案」, *deim2022*, 最終論文集, DEIM, 2022.
- [5]. M.A.Hearst, "TextTiling: Segmenting Text into Multiparagraph Subtopic Passages", *Computational Linguistics*, Vol.23, No.1, pp.33-64, 1997.
- [6]. 福田雅志, 延澤志保, 太原育夫: 「語彙的結束性に基づく話し言葉のテキストセグメンテーション」, 言語処理学会, 第 11 回年次大会予稿集, 2005.
- [7]. M. Riedl and C. Biemann, "TopicTiling: A Text Segmentation Algorithm based on LDA", *Proceedings of the 50th ACL* 2012, 2012.
- [8]. 山村崇, 鳩田和孝: 「語彙的連鎖とトピックモデルに基づくテキストセグメンテーション」, 言語処理学会, 第 22 回年次大会, 発表論文集 (2016 年 3 月)