

2024 年度 卒業論文

音声コンテンツの自動セグメント化と
トピックモデリングによる推薦システムの構築

Building a radio program recommendation system
through automatic segmentation and topic modeling of audio content

法政大学情報科学部

デジタルメディア学科

21K1127 野本 匠馬

指導教員：赤石 美奈

Abstract

Currently, a vast number of radio programs, podcasts, and other audio content are available in a wide variety of forms. However, it is time-consuming and difficult for users to search for programs they may like and for the parts of the programs that interest them. This is due to the fact that each program is composed of unique sections and talk zones, etc., and that the progress of each program and the content of each program varies depending on the mood of the personality facilitating the program, the amount of knowledge of the personality on the topic at that time, and the current trends in the world. Because of this, users must actually listen to the entire program in order to decide whether they like the program or not. Therefore, they have to listen to what they are not interested in before they can listen to what they are interested in. In addition, some programs may be broadcast for long periods of time, so users need to wait for those times. An example is “Audrey's All Night Nippon. Assume that the appeal of this program is that it is a program with a popular comedian duo as personalities, that it has been running for more than 10 years, and that stories about their high school days are popular. However, if it is broadcast late at night and the air time is two hours, the user may find it a chore to listen. Also, if the user is interested in high school stories, he or she may stop listening because he or she has to listen to the part that does not interest him or her before listening to the part that does. In this case, the problem of users having to wait for the start of the broadcast can be solved by using the time-free function of the Internet radio station radiko, which allows users to listen to programs broadcast within the past week, or by using archived podcasts. On the other hand, however, the problem of having to listen to programs that do not interest them due to the need to listen for long periods of time has not been solved.

The use of SNS data allows for recommendations that reflect the opinions of users. In addition, by evaluating whether the user liked the programs he/she listened to for each program and using collaborative filtering, it is possible to identify users who have similar tastes to the user making the recommendation, and to recommend programs that are highly rated by these users as highly rated by the user making the recommendation. However, since the existing method recommends programs as a whole, the user does not know which broadcasts talk about what he or she is interested in. Therefore, it is necessary to find the broadcast session in which the user is interested and find the part of the program in which the user is interested. Thus, the problem of having to listen to uninteresting parts in order to find the part of interest has not been solved. Therefore, a recommendation method that allows the user to listen to a program from the part of the program in which he/she is interested is desirable. Therefore, it is necessary to divide programs by content topic.

In this study, we propose a system that divides radio programs by topic to create topic segments and recommends them according to user interest. In this study, a topic is a topic spoken in a program and a topic segment is audio data spoken about a single topic. Since topic segments are divided by topic, users can listen to the topics they are interested in first. Also, the time required to listen to a topic segment is shorter than the time before the segmentation, so the user can easily listen to it. Thus, the problem of having to listen to uninteresting topics can be solved.

目次

1. はじめに	4
2. 関連研究	6
3. トピックセグメント推薦システム	7
3.1. トピックセグメント推薦システムの構築	7
3.2. トピックセグメント分割部	8
3.2.1. 番組音声データ分割	9,
3.2.2. 発話音声データ分割	12
3.3. トピックセグメント推薦部	15
4. 評価実験	16
4.1. 実験方法	16
4.2. 実験結果	17
4.3. 考察	17
5. まとめ	20
謝辞	22
文献	24

1. はじめに

現在、多種多様な形で膨大な数のラジオ番組やポッドキャストなどの音声コンテンツが配信されている。しかし、ユーザー自身がその中から気に入りそうな番組や番組内におけるユーザーの興味のある部分を探すことは時間や手間がかかり困難である。これは各番組がそれぞれ特徴のあるコーナーやトークゾーン等で構成されていることや番組の進行を務めるパーソナリティの気分やその時の話題におけるパーソナリティの知識量、世間のトレンドなどによって、各回の番組の進行や話される内容や異なることが原因である。このようなことから、番組を気に入るかどうか判断するために、ユーザーは実際に番組全体を聴かなければならない。そのため、興味のあることについて聴くまでに興味のないことも聴く必要がある。また、番組によっては長時間放送されている場合があるため、ユーザーはその時間帯に合わせて待機する必要がある。例として、「オードリーのオールナイトニッポン」を挙げる。この番組のアピールポイントは、人気のあるお笑い芸人コンビがパーソナリティを務める番組で、10年以上継続しており、高校時代の話が人気であるとする。しかし、それが深夜放送で放送時間が2時間だとすると、ユーザーは聴くことを面倒だと感じる可能性がある。また、このユーザーが高校時代の話に興味のあることとしている場合、その部分を聴く前に興味のない部分を聴くこととなることから、視聴をやめてしまう可能性がある。この場合では、インターネットラジオである radiko の過去一週間以内に放送された番組が聴けるタイムフリー機能やポッドキャストによるアーカイブ配信を利用することで、ユーザーが放送開始時間に待機していなくてもはならない問題は解決できている。しかし、一方で長時間聴く必要があることから、興味のないことも聴かなくてはならない問題は解決できていない。

ラジオ番組の推薦手法には Twitter 等の SNS データを用いた手法やそれに協調フィルタリングを用いた手法が挙げられる。SNS データを用いることで、ユーザーの意見を反映した推薦を行うことができる。また、各番組に対して聴いた番組が気に入ったかどうかの評価を行い、協調フィルタリングを用いることで、推薦を行うユーザーと類似した好みを持つユーザーを特定し、このユーザーが高評価している番組は推薦を行うユーザーも高評価をすることで推薦することができる。しかし、既存手法で推薦するのは番組全体であるので、ユーザーは興味のあることについて話している放送回がどれか分からない。そのため、興味のあることについて話されている放送回を見つけ、興味のあることについて話されている部分をその回から見つける必要がある。このようなことから、興味のある部分を探すために、興味のない部分も聴かなくてはならない問題は解決できていない。このことから、ユーザーの興味のある部分から番組を聴かせるような推薦手法が望まれる。したがって、番組を内容の話題ごとに分割する必要がある。

本研究では、ラジオ番組をトピックで分割してトピックセグメントを作成し、ユーザーの興味に応じてそれらを推薦するシステムを提案する。本研究において、トピックは番組内で話されている話題、トピックセグメントは1つのトピックについて話されている音声データである。トピックセグメントは1つのトピックについて話されているため、ユーザーは興味のあるトピックのみについて聴くことができる。そして、トピックセグメントを聴くために要する時間は分割する前の時間より短くなるので、ユーザーは気軽

に聴くことができる.これらのことから,興味のないトピックも聴かなくてはならない問題を解決できる.
また,本システムで作成したトピックセグメントにおいて,それに付与されているトピックの内容とトピックセグメントの内容が意味的に類似しているか調査を行った.用意した 100 個のトピックセグメントの内,9 割程度のトピックセグメントに類似したトピックを付与できていた.

2. 関連研究

ラジオ番組の推薦手法には、SNS データを用いた手法やそれに協調フィルタリングを用いた手法がある[1]. 丸山らは、提案されているラジオ番組推薦手法の評価を行い、Twitter 上のユーザーコミュニティを活用した協調フィルタリングやグラフベース手法が有効であることを明らかにしている[2]. Fernández-García らは、ラジオ番組の音楽とトークの割合、音楽のジャンル、扱うトピック、声のトーンを反映した推薦システムを開発した[3]. 太田らは、ラジオリスナーのユーザー体験向上のために、Twitter のデータを用いてラジオ番組の盛り上がっている区間を推定し、その区間以外を高速化することでラジオ番組の圧縮手法を提案した[4].

データをトピックで分割する手法としてトピックセグメンテーション手法である Text Tiling が挙げられる[5]. Text Tiling は文書のある境界において、左右に一定の単語数を保持する窓と呼ばれるブロックに分ける. そして、左右のブロックの類似度を求め、両方のブロックを左から右に進める. この操作を繰り返し、類似度の谷をトピックが変わった場所と見なして分割する手法である. 福田らは、話し言葉は文法的な表現が安定しないことから、文書内の語の共起関係に着目し、意味的に近い語がまとまっている部分をセグメントとする手法を提案した[6]. また、Text Tiling を発展させた手法として、Topic Tiling が提案されている[7]. Topic Tiling では、左右の窓に対してトピックモデルである LDA を適用してベクトルにする. 左右のベクトルのコサイン類似度から窓間の結束度を計算する手法である. 山村らは、語彙的連鎖を利用して分割を行う LC-seg と、LDA がどちらも異なる情報を用いていることから、両手法を組み合わせた手法を提案している[8].

既存手法は番組を聴いたリスナーの感想を解析しているので、番組に対するユーザーの声を反映させることができる. しかし、SNS データを用いた手法では、データに間違った情報や偏った情報などのノイズが存在していた場合に適切な推薦が困難になる. また、協調フィルタリングでは、過去データがない新規ユーザーに対しての推薦が困難である. そして、既存手法では番組単位で推薦しているため、興味のあるトピックが話されている部分を聴くまでに、興味のないトピックについて話されている部分も聴かななくてはならない問題を解決できていない.

本研究では、番組をトピックで分割してトピックセグメントにすることで、ユーザーは興味のあるトピックから聴けることを可能にすることで、興味のない部分も聞く必要がある問題を解決している. また、ユーザーは推薦されたセグメントから番組が面白いかどうかを暫定的に判断することができる. 面白いと判断した場合、その番組の他のトピックセグメントや実際の番組を聴くことで、その番組のリピーターになる可能性が高まる.

3. トピックセグメント推薦システム

3.1. トピックセグメント推薦システムの構築

トピックセグメント推薦システムの全体図を図 1 に示す. 本システムはラジオ番組をトピックセグメントに分割するトピックセグメント分割部とユーザーの興味に応じてトピックセグメントを推薦するトピックセグメント推薦部から構成される. まず, ラジオ番組から発話部分を取得し, これをトピックで分割することでトピックセグメントを作成する. また, トピックの情報を参照・取得するために, トピック辞書とトピックセグメントデータベースを用いる. トピック辞書はラジオ番組の文字起こしテキストデータから推定した各トピックの識別番号, 関連名詞, 関連名詞ごとの生起確率などの情報を保持した辞書である. トピックセグメントデータベースは作成したトピックセグメントとトピックセグメントが保持する情報をトピックごとに複数個格納できるデータベースである. そして, ユーザーの入力とトピック辞書から類似トピックを特定し, これに対応するトピックセグメントをデータベースから取得して, ユーザーに推薦する. 類似トピックとは, 番組内のトピックに対して, ユーザーの興味のあることに類似したトピックである. 本システムの各モジュールの詳細は次項以降行う.




図 1: トピックセグメント推薦システムの全体図

3.2. トピックセグメント分割部

図 2 にトピックセグメント分割部の全体像を示した. まず, ラジオ番組から番組音声データを取得する. 次に番組音声データから音楽・CM 部分を除去し, 発話音声データを抽出する. 次に, これに対して文字起こしを行い, 発話テキストを取得する. このとき, 発話テキストからトピックモデルを構築して, トピックの生起確率が高い上位 10 個の名詞群とその名詞群のそれぞれの生起確率などの情報を保持するトピック辞書を作成する. 発話テキストからトピックを推定し, 同じトピックが連続している区間を特定する. そして, 特定した区間を発話音声データから切り出すことで, トピックセグメントを作成する. これらをトピックごとにトピックセグメントデータベースに格納する. 各処理の詳細な説明は次項以降で行う.




図 2: トピックセグメント分割部

3.2.1. 番組音声データ分割

ラジオ番組はパーソナリティの発話部分とジングルなどの音楽部分、企業などの CM 部分の 3 つの部分から構成される。本システムでは、番組をトピックで分割するため、番組の内容が 3 つの部分の内、どれに該当するか定義する必要がある。本研究では、番組の内容をパーソナリティの発話部分とし、発話部分を文字起こししたテキストをトピックで分割することで番組とトピックで分割する。このことから、番組から取得した番組音声データからパーソナリティの発話部分のみを抽出する必要がある。このため、番組音声データから音楽部分と CM 部分を除去することで、発話部分である発話音声データを取得する。

まず、番組音声データから音楽部分を除去するためにスペクトル解析を行う。ラジオ番組では、コーナーやトークゾーンなどの開始時と終了時にジングルが流れ、その後に無音区間が存在する特徴を利用する。スペクトル解析には Python の音響解析及び信号処理のライブラリである Librosa を用いた。また、音声データの分割は音声ファイルを入出力するためのライブラリである Pydub を用いた。図 3 に「星野源のオールナイトニッポン」、図 4 に録音した音声データに対して、それぞれスペクトル解析を行った結果を示した。2 つの図において、横軸は音声の時刻、縦軸は音声の周波数で、各点の色はその時刻におけるその周波数の音の強度を示している。赤色の部分は音の強度が強くなっている部分で、青色の部分は音の強度が弱くなっている部分である。2 つの図から、複数の時刻の音の強度において、その前後の時刻より音の強度が弱い部分が存在することがわかる。この部分に対応している時間の元の音声データではジングルが流れていた。このことからスペクトル解析を行い、音の強度が閾値より弱い区間を検出し、この区間を音楽部分とすることで、番組音声データを音楽部分で分割する。しかし、分割した音声データが CM 部分を含んでいる場合があるので、分割したデータをさらに話者分離を用いて分割する。

スペクトル解析で除去できなかった CM 部分を除去するために話者分離を行う。本研究では、音声データ内で 60 秒以上発話している話者をメインスピーカーと定義した。メインスピーカーが 30 秒以上発話していなかった時に、CM 部分に遷移したと認識して分割を行う。話者分離にはオープンソースフレームワークである pyannote.audio を用いた。図 5 に「星野源のオールナイトニッポン」の発話音声データに対して、この話者分離を行った結果を示す。図 5 は上の行から下の行へ時系列順になっており、左から発話者、発話者の発話開始時間、発話者の発話終了時間を表している。この発話音声データでは SPEAKER_03 がメインスピーカーとされていた。図 5 の 8 行目の終了時刻と 9 行目の開始時刻の差が約 163 秒となっているため、CM 部分に遷移したと認識されて分割が行われている。このようにスペクトル解析と話者分離を用いることで、ラジオ番組から音楽部分と CM 部分を除去した。




図 3: 「星野源のオールナイトニッポン」のスペクトグラム




図 4: 録音した音声データのスペクトグラム

```
発話者：SPEAKER_03, 開始時刻：665.46284375, 終了時刻：666.3572187500001
発話者：SPEAKER_03, 開始時刻：666.7453437500001, 終了時刻：669.24284375
発話者：SPEAKER_03, 開始時刻：669.47909375, 終了時刻：679.75596875
発話者：SPEAKER_03, 開始時刻：680.1440937500001, 終了時刻：691.04534375
発話者：SPEAKER_03, 開始時刻：692.1928437500001, 終了時刻：692.44596875
発話者：SPEAKER_03, 開始時刻：702.85784375, 終了時刻：706.1484687500001
発話者：SPEAKER_03, 開始時刻：706.62096875, 終了時刻：708.5615937500002
発話者：SPEAKER_03, 開始時刻：709.18596875, 終了時刻：709.9453437500001

発話者：SPEAKER_03, 開始時刻：872.9240937500001, 終了時刻：876.1809687500001
発話者：SPEAKER_03, 開始時刻：876.53534375, 終了時刻：878.2903437500001
発話者：SPEAKER_03, 開始時刻：878.6615937500001, 終了時刻：879.60659375
発話者：SPEAKER_03, 開始時刻：879.9440937500001, 終了時刻：881.3953437500002
発話者：SPEAKER_03, 開始時刻：881.68221875, 終了時刻：882.7453437500001
発話者：SPEAKER_03, 開始時刻：882.94784375, 終了時刻：883.9265937500002
```

図 5: 「星野源のオールナイトニッポン」のある発話音声データの話者分離の実行結果

3.3.2 発話音声データ分割

ラジオ番組の内容をトピックで分割するためにトピックモデルである LDA (潜在的ディリクレ配分法) を用いる. LDA はテキストデータからトピックを推定するため, 発話音声データを文字起こしして発話テキストを取得する. また, 発話テキストから LDA を構築し, 生成したトピックの関連名詞とその生起確率を保持したトピック辞書を作成する. 本研究では, トピックの流れを細かく見るために発話テキストの連続する N 行をトークンとした N-gram を 1 つの窓とした Topic Tiling を行う. これによって, 同じトピックが連続している区間を特定する. そして, この区間の発話テキストに対して, トピック辞書を用いてトピックを推定することでトピックセグメントを作成する. トピックセグメントとこの情報をトピックセグメントデータベースに格納する.

発話音声データから発話テキストを取得するために, faster-whisper の large-v3 モデルを用いて文字起こしを行った. このとき, 各発話の開始時刻と終了時刻を同時に取得する. 図 6 の左は「星野源のオールナイトニッポン」の一部を文字起こしした結果である. しかし, Topic Tiling を行うとき, フィラーや名詞が含まれない文などの発話内容に関係のない行は同じトピックが連続している区間を見つける際のノイズとなる可能性があるため, このような行は除去する. 除去した文字起こし結果を図 6 の右に示す.

発話音声データの内容からトピックを推定するためにトピックモデルである LDA を用いる. 本研究では, トピックとなり得る単語の品詞は名詞であり, かつ一般名詞と固有名詞, サ変接続の名詞をトピックとなり得る名詞とした. 複数の発話テキストで LDA モデルを構築することで, 発話テキストのトピックの生起確率をトピック分布として取得できる. また, 各トピックにおいて生起確率が高い単語を単語分布として取得できる. 名詞のみを抽出するために日本語形態素エンジンの MeCab を用いる. また, 形態素解析を行う際には, 名詞-一般, 名詞-固有名詞, 名詞-サ変接続である名詞を取得し, 新語や固有名詞に対応するために形態素解析用辞書の NEologd を適用する. しかし, このように構築した MeCab では, 「いやいや」, 「わからん」などの感動詞の組み合わせや動詞と助動詞の組み合わせが 1 つの名詞として取得されてしまう. これは NEologd が過剰に名詞を取得してしまうことが原因である. このことから, この MeCab で名詞を取得した後に, 各名詞に対して, IPA 辞書を適用した MeCab を用いて, 助詞や助動詞を含む名詞, 名詞が含まれない名詞を除去することで, 過剰に名詞を取得してしまう問題を解決する. LDA モデルの実装には様々なトピックモデルを実装したライブラリである gensim を用いる. また, 抽出した名詞のベクトル変換には東北大学の乾研究室が公開している事前学習済み日本語 BERT モデルを用いる. 以降, BERT はこのモデルを用いる.

発話テキストから LDA モデルを構築し, 生成したトピックの単語分布における生起確率の上位 10 個の関連名詞とその生起確率を保持するトピック辞書を作成する. LDA モデルで発話テキスト内の名詞の共起関係からトピックに関係する名詞を推定していることから, トピック辞書に存在するある名詞は複数のトピックで存在する場合がある. このとき, トピック辞書の 1 つのトピックが 1 つの意味的なまとまりを保持するようにトピック辞書を調整する. まず, 生起確率が閾値以下の関連名詞を除去する. 除去後

の関連名詞を BERT でベクトルに変換する.そして,ベクトル間の類似度を基準としたクラスタリングを行う.このとき,クラスタが複数個存在していた場合,1つのトピックに対して,複数の意味的なまとまりが存在することとなる.ここで,1つのトピックが1つの意味的なまとまりを保持するようにクラスタごとにトピックを分ける.例として,トピック k が関連名詞として,['音楽', 'ジャズ', 'ギター', '芋', 'ポテト', '油']を保持していたとする.このとき,関連名詞をクラスタリングすると['音楽', 'ジャズ', 'ギター'], ['芋', 'ポテト', '油']のクラスタに分けることができる.ここで,['音楽', 'ジャズ', 'ギター']をトピック k ,['芋', 'ポテト', '油']をトピック $k+1$ とすることで,1つのトピックが1つの意味的なまとまりを保持するようにする.

発話テキストにおいて,連続する N 行をトークンとした N -gramを1つの窓とした Topic Tiling を行う.まず,この N -gramのトピック分布を表すベクトルの各次元を0で初期化する.次に N -gramから名詞群を抽出し,それぞれの名詞において,トピック辞書のトピック k にその名詞と同じ関連名詞が存在していた場合,この N -gramのベクトルにおいてトピック k に対応する次元にこの関連名詞の生起確率を加算する.そして,全ての名詞でこの処理を行った後にベクトルを正規化する.次に,この N -gramの先頭の行から N 行分だけ先に進めた行から N -gramの窓を作成し,同様にトピック分布を表すベクトルを作成する.そして,2つのベクトルのコサイン類似度を計算する.そして,2つの N -gramの窓をそれぞれ1行分だけ先に進める.全ての窓間の類似度を計算し,窓間の類似度が閾値以上または閾値未満に切り替わる時点で発話テキストを分割する.分割したテキストに対して,トピック辞書を用いてトピックを推定する.そして,この部分に対応する発話音声データを切り出すことでトピックセグメントを作成する.これをトピックごとにトピックセグメントデータベースに格納する.

[0. 40, 2. 52]::どうもこんばんは星野源です
 [2. 52, 10. 44]::今日は2024年9月10日火曜日25時
 でございます
 [10. 44, 16. 92]::そして星野源のオールナイトニッポ
 ンがなんと398回ってことで
 [16. 92, 18. 88]::おーやりましたねやってますね
 [18. 88, 21. 88]::もうちょっとで400回ってことで
 [21. 88, 25. 00]::今日は通常放送かと思いきや
 [25. 54, 27. 18]::オールナイトニッポン全体がですね
 [27. 18, 29. 34]::1週間ミュージックウィークという
 ことで
 [29. 34, 33. 22]::いつもねいろんな芸人さんやら俳優
 さんやら
 [33. 22, 34. 98]::いろんな方がいますけれども
 [34. 98, 39. 56]::今日はミュージシャンばかりが出
 る週ということで
 [39. 56, 43. 10]::いつもは出ない方々などがこの1週
 間ね
 [43. 10, 45. 56]::いろいろにぎにぎにぎにぎしており
 ます
 [45. 56, 49. 60]::で僕とあのちゃんだっけだっけあれ
 [49. 60, 52. 30]::あと北谷さんだそうだ北谷さん
 [52. 30, 56. 10]::お会いしたこと多分ちゃんとお話し
 したことはないんですけど
 [56. 34, 58. 44]::北谷さんとかは
 [58. 44, 58. 70]::えー
 [58. 70, 61. 48]::もともとね音楽の人なので

[0. 40, 2. 52]::どうもこんばんは星野源です
 [2. 52, 10. 44]::今日は2024年9月10日火曜日25時
 でございます
 [10. 44, 16. 92]::そして星野源のオールナイトニッポ
 ンがなんと398回ってことで
 [18. 88, 21. 88]::もうちょっとで400回ってことで
 [21. 88, 25. 00]::今日は通常放送かと思いきや
 [25. 54, 27. 18]::オールナイトニッポン全体がですね
 [27. 18, 29. 34]::1週間ミュージックウィークという
 ことで
 [29. 34, 33. 22]::いつもねいろんな芸人さんやら俳優
 さんやら
 [34. 98, 39. 56]::今日はミュージシャンばかりが出
 る週ということで
 [39. 56, 43. 10]::いつもは出ない方々などがこの1週
 間ね
 [43. 10, 45. 56]::いろいろにぎにぎにぎにぎしており
 ます
 [49. 60, 52. 30]::あと北谷さんだそうだ北谷さん
 [56. 34, 58. 44]::北谷さんとかは
 [58. 70, 61. 48]::もともとね音楽の人なので

図6:「星野源のオールナイトニッポン」の文字起こし結果
 (左: 内容に関係のない文を含む, 右: 内容に関係のない文は除去)

3.3. トピックセグメント推薦部

図7にトピックセグメント推薦部の全体像を示した。トピックセグメント推薦機能では、ユーザーに興味のあることの文を入力させる。次に、ユーザーの興味のあることとトピック辞書から類似トピックを特定する。そして、類似トピックに対応するトピックセグメントを推薦する。

まず、ユーザーが入力した興味のあることについての文から名詞を抽出する。抽出した名詞とトピック辞書から類似しているトピックを特定する。抽出した名詞とトピック辞書のあるトピックの関連単語群との類似度が閾値以上となるトピックを類似トピックとする。

本研究では、トピック類似度の計算にコサイン類似度を用いる。そのため、抽出した名詞や関連単語をBERT でベクトルにする。そして、抽出した名詞と関連単語について、コサイン類似度を計算する。各関連単語の類似度の平均値をトピック類似度として扱う。全てのトピックに対してトピック類似度を計算し、閾値以上のトピックを類似トピックとする。特定した類似トピックに対応しているトピックセグメントを取得し、推薦する。

本研究では、取得したトピックセグメントにおいて、類似トピックの生起確率が高い順に推薦を行う。また、生起確率と同じである場合には、トピックセグメントの再生時間が短いものを先に推薦する。




図7: トピックセグメント推薦部

4. 評価実験

本実験では、ユーザーの興味のある部分のみを推薦するために、ユーザーが聴きたい形にトピックセグメントを整形できているか分析する。トピックセグメント内に複数のトピックが含まれている場合、ユーザーは興味のないトピックについても聴かなくてはならない。そのため、興味のない部分も聴かなくてはならない問題を解決できない。このため、トピックセグメントには1つのトピックのみ含まれるようにすべきである。本実験では、トピックセグメントの内容と実際にトピックセグメントに付与されているトピックの内容が意味的に類似しているか計算する。トピックセグメントとトピックが類似している場合、そのトピックセグメントを正解と見なす。そして、トピック辞書の調整の有無とトピック辞書を調整する際のパラメータの変化によって、用意したトピックセグメントの内、トピックセグメントの正解率の変化を調査する。

4.1. 実験方法

本システムにおいて、推薦に用いるラジオ番組の番組音声データは、パーソナリティの発話部分とジングル等の音楽部分、CM 部分から構成されている必要がある。本実験で用いるデータとして、2024 年 6 月 24 日から 2024 年 12 月 24 日までで取得できた「星野源のオールナイトニッポン」の 18 回分の放送の音声データから LDA モデルを構築し、トピックセグメントを作成した。また、ラジオ番組の文字起こしテキストデータからトピックの識別番号、関連名詞、関連名詞ごとの生起確率を保持したトピック辞書を作成する。

まず、トピック辞書を調整しない場合でトピックセグメントを作成し、それぞれのトピックセグメントの内容を表すベクトルを作成する。トピックセグメントの発話テキストから名詞群を抽出し、これらの名詞を BERT でベクトルに変換する。ここで、この名詞群の平均ベクトルを計算する。そして、ベクトル間の類似度を基準としたクラスタリングを行う。ここで、保持するベクトル数が最も多いクラスタをこのトピックセグメントの代表クラスタとし、代表クラスタが保持するベクトルの平均ベクトルをこのトピックセグメントの代表ベクトルとする。

次に、トピックセグメントに付与されているトピックの内容を表すベクトルを作成する。トピックの関連名詞の生起確率が閾値以下の関連名詞を除去する。除去後の関連名詞を BERT でベクトルに変換する。ここで、この関連名詞の平均ベクトルを計算する。そして、ベクトル間の類似度を基準としたクラスタリングを行う。ここで、保持するベクトル数が最も多いクラスタをこのトピックの代表クラスタとし、代表クラスタが保持するベクトルの平均ベクトルをこのトピックの代表ベクトルとする。

トピックセグメントの内容と付与されたトピックの内容が意味的に類似しているか分析するために、トピックセグメントとこれに付与されているトピックそれぞれの平均ベクトルと代表ベクトルのコサイン類似度を計算する。トピック辞書を調整する場合でも同様の処理を行い、トピックセグメントと付与されたトピックが意味的に類似しているかどうか分析する。ここで、2 つのベクトルのコサイン類似時

度が閾値以上であれば、そのトピックセグメントを正解と見なす。用意した 100 個のトピックセグメントにおいて、トピック辞書を調整しない場合とトピック辞書の調整で、それぞれクラスタリングを行う際のベクトル間の類似度のパラメータ、クラスタが最低限保持するベクトル数のパラメータを変化させた場合、それぞれの場合におけるトピックセグメントの正解率を比較する。

4.2. 実験結果

クラスタリングを行う際のベクトル間の類似度を **Similarity**、クラスタが最低限保持するベクトル数を **Cluster size** とする。ここでは、トピックセグメントの内容とこれに付与されたトピックの内容の平均ベクトルのコサイン類似度が閾値以上のトピックセグメントを正解と見なし、トピックマッチセグメントとする。図 8 に用意した 100 個のトピックセグメントにおいて、トピック辞書を調整した場合と調整しなかった場合に **Similarity** と **Cluster size** を変化させたときのトピックマッチセグメントの割合を示した。横軸はトピックセグメントを正解と見なすときの類似度の閾値である。縦軸は正解率つまり類似度が閾値以上のトピックマッチセグメントの割合を示している。グラフの赤線がトピック辞書を調整しない場合、青線がトピック辞書を調整した場合のトピックマッチセグメントの割合である。また、横軸の閾値を 0.05 から 1.0 まで 0.05 ずつ増加させることで、トピックマッチセグメントの割合の変化を見る。

4.3. 考察

本システムにおいて、**Similarity** の値が大きくなれば、トピック辞書の関連名詞は意味的に強く類似しているまとまりを持つようになる。このとき、**Cluster size** を大きくすると、トピック辞書の関連名詞は強く類似しており、かつこのような関連名詞を多く持つようになる。このことから、**Similarity** と **Cluster size** を同時に大きくすれば、トピック辞書の関連名詞は意味的に類似している名詞の大きなまとまりを保持していることとなる。このトピック辞書を用いて **Topic Tiling** を行い、トピックセグメントにトピックを付与することで、そのトピックについてだけを話しているトピックセグメントを作成できる。


図 8 の (a)、(b)を見ると、**Cluster size** が 2 のとき、閾値が 0.85 以上であれば、トピック辞書を調整した場合のトピックマッチセグメントの割合は調整しなかった場合のトピックマッチセグメントの割合以下だった。また、閾値が 0.8 以下であれば、(a)では、トピック辞書を調整した場合の割合が調整しなかった場合の割合をわずかに下回っていた。(b)では、トピック辞書を調整した場合の割合が調整しなかった場合の割合をわずかに上回っていた。これはクラスタを形成する最小クラスタサイズを小さくしたことで、関連名詞が小さなまとまりであっても、このまとまりがトピック辞書の関連名詞に保持されることが原因であると考えられる。関連名詞が小さなまとまりであっても、それがトピック辞書に保持されることで、細かいトピックも認識して、このようなトピックが付与されているトピックセグメントを作成することができる。(a)では、**Similarity** が 0.7 であるので、関連名詞を小さいまとまりと見なしやすい。しかし、このようなトピックが付与されているトピックセグメントには関連名詞以外の名詞が多く含まれている可能性があ

る.このとき,トピックセグメントの平均ベクトルと付与されているトピックの平均ベクトルのコサイン類似度は低くなってしまふ.したがって,調整したトピック辞書の場合のトピックマッチセグメントの割合が調整しなかった場合の割合を下回っていた.また,Similarity が 0.8 の場合では,0.7 の場合と比べて,関連名詞をまとまりと見なす条件が厳しくなっていることから,トピック辞書を調整した場合のトピックマッチセグメントの割合が調整しなかった場合の割合を上回っていた.


図 8 の(c), (e)を見ると,トピック辞書を調整した場合のトピックマッチセグメントの割合と調整しなかった場合の割合に大きな差は見られなかった.これは,トピック辞書を調整した場合と調整しなかった場合のそれぞれで同じようなトピックセグメントが作成されたことが原因であると考ええる.Similarity を 0.7 として,トピック辞書を調整することで,元のトピック辞書の関連名詞で意味的に類似しているまとまりを多く調整後のトピック辞書に保持させることができる.このことから,調整したトピック辞書を用いてトピックセグメントを作成しても,調整しなかった場合と同じようなトピックセグメントが作成されたと考える.また,Cluster size が大きくなり,関連名詞をまとまりと見なす条件が厳しくなることで,より大枠な関連名詞をトピック辞書が保持されたことも原因であると考ええる.そして, (c)と(d)を比べたとき,閾値が 0.5 以上 0.8 以下において,(d)の方がトピック辞書を調整した場合のトピックマッチセグメントの割合が調整しなかった場合の割合を上回っていた.これは,Cluster size が大きくなることでより大枠な関連名詞をトピック辞書に保持させることができたことが原因であると考ええる.

図 8 の(d), (f)を見ると,閾値が 0.6 以上 0.9 以下において,トピック辞書を調整した場合のトピックマッチセグメントの割合は調整しなかった場合の割合を上回っていた.特に,閾値を 0.8 としたとき,トピック辞書を調整した場合のトピックセグメントの割合が調整しなかった場合の割合より 20%程度上昇した.これは,Similarity と Cluster size を共に大きくすることでより大枠な関連名詞をトピック辞書に保持させることができたことが原因であると考ええる.このことから,用意した 100 個のトピックセグメントの内,トピックマッチセグメントが 9 割程度存在することがわかる.


このようなトピックセグメントには,そのトピックセグメントの内容に類似したトピックが付与されている.したがって,本システムはトピック辞書とトピックセグメントを用いることで,ユーザーの興味に類似したトピックを特定し,そのトピックに対応したトピックセグメントを推薦することが可能となる.




(a) [Similarity = 0.7 , Cluster size = 2]




(b) [Similarity = 0.8 , Cluster size = 2]




(c) [Similarity = 0.7 , Cluster size = 3]



(d) [Similarity = 0.8 , Cluster size = 3]



(e) [Similarity = 0.7 , Cluster size = 4]



(f) [Similarity = 0.8 , Cluster size = 4]

図 8: トピックマッチセグメントの割合

5. まとめ

本研究では、音声コンテンツをトピックで分割して、ユーザーの興味に基づいて音声コンテンツの推薦システムの構築を行った。本システムはユーザーの興味のあることについての文に対して、ユーザーの興味に類似したトピックをトピック辞書から特定し、これに対応しているトピックセグメントを推薦する。また、本研究では、トピック辞書を調整することによって、トピックセグメントの内容とこれに付与されているトピックの内容が意味的に類似しているものの割合が、調整しないときと比べてどの程度変化するかと比較実験を行った。比較実験からトピック辞書を調整することによって、用意したトピックセグメントの内、9 割程度に対して適切なトピックを付与できていた。このようなトピック辞書とトピックセグメントを用いることで、ユーザーの興味に類似したことを話しているトピックセグメントを推薦できる。このことから、本システムを利用することでユーザーは興味のあることから話しているラジオ番組を聴くことができる。

本システムでは、番組音声データを発話音声データに分割する際に、音楽部分であるジングルを検出することで音楽部分の除去を行なっている。しかし、本システムでは楽曲を検出することができていない。特にパーソナリティ本人が歌唱している部分を除去できていない。これによって、LDA モデルを構築するときの発話テキストにノイズが加わることとなるので、Topic Tiling で同じトピックが連続している区間を適切に特定できていない可能性がある。また、LDA モデルでいくつトピックを生成するかのパラメータや Topic Tiling の窓として用いている発話テキストの N-gram の N のパラメータを変更したときにトピックマッチセグメントの割合がどのように変化するか検討が必要である。また、本システムでは、発話テキストを faster-whisper の large-v3 で文字起こししているため、本来の人物名と異なる文字列で取得している場合がある。例として、パーソナリティが「キタニタツヤ」を「キタニ」として読んでいるが、発話テキスト上では「北谷」となっていた。また、人物名がフルネームで存在する場合と苗字だけで存在する場合などがあり、これらは違う固有名詞として存在することとなる。人物名はラジオ番組では頻繁に発話されるため、このような名詞はトピックを推定する際にノイズとなる可能性があるため、名寄せを行う必要がある。この名寄せを自動で行えるようにシステムの改良を行う。そして、本研究の実験では「星野源のオールナイトニッポン」の音声データを実験データとして用いている。トピック辞書の調整において、Similarity と Cluster size の 2 つのパラメータを調整することで、正解率を向上させている。しかし、他の音声データの場合、正解率が向上するパラメータの値が本実験と異なる可能性がある。ここで Similarity と Cluster size のパラメータを動的に設定できるようにする。これらが今後の課題である。

今後の展望として、トピック辞書を調整して取得できたトピックセグメントにおいて、ユーザーの興味に類似したトピックセグメントを実際に聴いてもらい、それがユーザーの興味に類似しているかの評価実験を行い、トピックセグメントの内容とトピックの内容の類似度がどの値以上であれば、ユーザーの興味と類似しているか実験を行う。また、ユーザーの興味について考えたとき、ユーザーの興味が人物についてだった場合、その人物がメインスピーカーとして話しているラジオ番組を推薦するのか、その人物につ

いて話しているトピックセグメントを推薦するのかの検討が必要である。トピックセグメントのトピックがユーザーの興味とどの程度類似していれば、それを聴くことができるのかについて考えたとき、これは個人差があると考えられる、このため、本システムをパーソナライズ化することで、ラジオ番組のユーザー体験の向上を目指す。また、ラジオ番組の内容を調べるときに、番組がどのようなトピックで構成されており、それらが時間経過でどのように遷移していくかを可視化する。このようにすることで、その放送回で何について話されているか視覚的に判断でき、どのような流れでそれらが話されているか理解できる。また、ラジオ番組の1つの放送回の流れだけでなく、トピックセグメント内のトピックの遷移を可視化して、短いトピックの遷移も認識できるようにすることで、番組の音声を聴くだけでなく視覚的にもラジオ番組を理解できるようにしたい。

謝辞

本研究, 本論文を作成するにあたり, 多大なるご指導を賜りました赤石教授, 相談に乗り, 実験に協力していただいた赤石研究室の皆様, 心より感謝申し上げます。

この1年間, 研究を進めるにあたって, 何度も壁にぶつかりました。私は研究テーマを決定したあたりから, 推薦システムの機能を実装することに注力してしまい, この研究における背景・問題や目的, 研究対象や用語の定義などを蔑ろにしてしまっていました。そのため, ゼミでの進捗発表や研究テーマの説明に際し, 教授や研究室の皆様からいただいたご助言, ご質問は, 私の研究をより良いものにするために欠かせないものでした。特に, 研究の進め方に関する指導には大変助けられました。

研究室の皆様とは, 毎週のゼミの進捗や中間発表会や卒業論文発表会前の発表練習で数多く議論を交わしたことが印象に残っています。皆様の研究内容には私の研究内容とも通じる部分も多くあり, 文字起こし機能では何のライブラリを用いているか, テキストセグメンテーションの手法はどのような既存手法があるかなど, 発表を通して聴くことで自分の研究にどのように取り入れるかの参考にさせていただきました。特にテキストセグメンテーションの手法の議論に関しては, 前述した通り実装に注力してしまい, 既存手法でどのようなものがあるか調べることもしませんでした。輪講の論文として, 取り上げてくれた須永君には感謝しております。また, 複数に分けてシステムの評価実験を行いました, 前述した通り, 実験の目的や評価指標を厳密に定義していなかったため, 行った評価実験については本論文に記載しないことといたしました。実験に協力していただいた研究室の皆様並びにサークルの後輩, 高校時代の同級生に感謝申し上げます。また, 貴重なお時間を頂いてしまったにも関わらず, 本論文に記載できなかったこと誠に申し訳ございませんでした。

赤石教授には学部4年次から大変お世話になりました。研究の進め方や各進捗発表においての問題点の明確にさせていただき, 行ったことの意味を論理的に説明できるように何度も大きな助言をいただきました。研究が本来の目的とは異なる方向へ進んでいたときや用いている概念の理解や定義が中途半端で研究・実装が停滞しているときに, 喝を入れていただいたことで軌道修正や不要な部分を除去することができました。また, 何度も研究の背景・問題や目的, 提案手法でやりたいこと, 行っていることのご質問を受けたことで, 研究室の皆様質問を行う際に自分と同じミスをしていないか考え, 質問を行うことができました。

赤石教授並びに修士の渡邊さんには, 大学院入試の際の研究テーマ決めやプレゼンテーションの練習に多大なるご協力をいただきました。研究の要点を的確に伝えるための資料作成や発表内容の構成について, ご助言をいただいたことで, より論理的で分かりやすい発表を行うことができました。お二人の的確なフィードバックを受け, 研究の本質を整理し直す機会を得られたことは, 私にとって大変貴重な経験となりました。この場を借りて, 改めて深く感謝申し上げます。また, 入試前夜, 緊張して眠れなくなっている際に「地獄で何が悪い」を聴くことで, 目標に向かって進み続けなければ, 当時の辛い状況が本当に辛いものになってしまうと思い, 最後までやり抜くことができました。

最後に、4年間一人暮らしの大学生活を支えてくれた家族、大学生活の心の支えとなっていた放送研究会の皆様にご心より感謝申し上げます。特に放送研究会では、自分の研究テーマの対象であるラジオやポッドキャスト等の音声コンテンツに触れる機会を与えてくれました。今後も自分の好きなことを探し、それを周りに伝えられるように取り組もうと思います。

文献

- [1]. 丸山 司, 岡本 一志, 柴田 淳司: 「SNS データを用いたラジオ番組推薦手法に関する調査」, The 36th Annual Conference of the Japanese Society for Artificial Intelligence, 2022.
- [2]. 丸山 司, 岡本 一志, 柴田 淳司: 「Twitter データ各要したラジオ番組推薦システムの検討」, DEIM Forum, 2023, 3b-7-1.
- [3]. Antonio Jesús Fernández-García, Roberto Rodriguez-Echeverria, Juan Carlos Preciado, Jorge Perianez, Juan D. Gutiérrez: “A hybrid multidimensional recommender system for radio programs”. Expert Systems with Applications, Vol. 198, p. 116706, 2022.
- [4]. 太田暢, 村山太一, 矢田竣太郎, 荒牧英治, 若宮翔子: 「Twitter を用いたラジオ番組圧縮手法の提案」, deim2022, 最終論文集, DEIM, 2022.
- [5]. M.A.Hearst, “TextTiling: Segmenting Text into Multi-paragraph Subtopic Passages”, Computational Linguistics, Vol.23, No.1, pp.33-64, 1997.
- [6]. 福田雅志, 延澤志保, 太原育夫: 「語彙的結束性に基づく話し言葉のテキストセグメンテーション」, 言語処理学会, 第 11 回年次大会予稿集, 2005.
- [7]. M. Riedl and C. Biemann, “TopicTiling: A Text Segmentation Algorithm based on LDA”, Proceedings of the 50th ACL 2012, 2012.
- [8]. 山村崇, 鳩田和孝: 「語彙的連鎖とトピックモデルに基づくテキストセグメンテーション」, 言語処理学会, 第 22 回年次大会, 発表論文集 (2016 年 3 月)